

Classificação de Tecidos Histopatológicos Utilizando Redes Neurais Profundas e Técnicas de Explainable AI no Dataset PathMNIST

Erik Holanda Pires, Carlos Daniel Reis da Silva, Raul Ferreira Holanda

erikholandapires@gmail.com, reisdaniel739@gmail, raulfholanda@gmail.com

¹ Curso de Sistemas de Informação
Centro Universitário Católica de Quixadá (UniCatólica)
Quixadá – Ceará – Brasil

Resumo. A classificação automática de imagens histopatológicas tem se tornado uma importante aplicação da Inteligência Artificial na área da saúde, auxiliando profissionais na identificação de padrões celulares e contribuindo para o diagnóstico médico. Este trabalho apresenta um estudo comparativo entre diferentes arquiteturas de redes neurais aplicadas ao dataset PathMNIST, composto por nove classes de tecidos histopatológicos coloridos. Inicialmente, foi desenvolvida uma rede Multilayer Perceptron (MLP) utilizando NumPy puro, posteriormente reproduzida em PyTorch para validação da implementação. Em seguida, foram avaliadas arquiteturas convolucionais e modelos baseados em Vision Transformers, incluindo CNN própria, ResNet50, EfficientNet-B0, MobileNetV3 Large e ViT-B/16, utilizando estratégias de feature extraction e fine-tuning. O melhor desempenho foi obtido pelo modelo ResNet50 em modo fine-tuning, alcançando acurácia de validação de 99,29%. Na avaliação final sobre o conjunto de teste oficial, o modelo atingiu acurácia de 96,71% e F1-Score Macro de 95,41%. Adicionalmente, técnicas de Explainable Artificial Intelligence (XAI), como Feature Maps e Grad-CAM, foram utilizadas para interpretar as decisões do modelo. Os resultados demonstram a eficácia do aprendizado profundo na classificação de tecidos histopatológicos e evidenciam o potencial das técnicas de interpretabilidade para aumentar a transparência dos sistemas de apoio ao diagnóstico.

Abstract. Automatic histopathological image classification has become an important application of Artificial Intelligence in healthcare, assisting specialists in identifying cellular patterns and supporting medical diagnosis. This work presents a comparative study of different neural network architectures applied to the PathMNIST dataset, which contains nine classes of colored histopathological tissues. Initially, a Multilayer Perceptron (MLP) was implemented using pure NumPy and later reproduced in PyTorch for validation purposes. Subsequently, convolutional neural networks and Vision Transformer-based models were evaluated, including a custom CNN, ResNet50, EfficientNet-B0, MobileNetV3 Large, and ViT-B/16, using feature extraction and fine-tuning strategies. The best performance was achieved by the ResNet50 model in fine-tuning mode, reaching a validation accuracy of 99.29%. During the final evaluation on the official test set, the model achieved 96.71% accuracy and a macro F1-score of 95.41%. Furthermore, Explainable Artificial Intelligence (XAI) techniques,

such as Feature Maps and Grad-CAM, were employed to interpret model decisions. The results demonstrate the effectiveness of deep learning approaches for histopathological tissue classification and highlight the importance of interpretability techniques in medical decision-support systems.

1. Introdução

A análise histopatológica é uma das principais ferramentas utilizadas no diagnóstico de diversas doenças, incluindo diferentes tipos de câncer. Tradicionalmente, esse processo é realizado por especialistas que examinam amostras de tecido por meio de microscopia, identificando características celulares e estruturais que permitam determinar alterações patológicas. Embora seja considerado um método altamente confiável, o procedimento pode demandar tempo, experiência profissional e estar sujeito à variabilidade de interpretação entre avaliadores.

Nos últimos anos, o avanço das técnicas de Inteligência Artificial (IA), especialmente das Redes Neurais Profundas (*Deep Learning*), possibilitou o desenvolvimento de sistemas capazes de auxiliar a análise de imagens médicas de forma automatizada. Entre as aplicações mais promissoras destacam-se os métodos de classificação de imagens histopatológicas, que buscam identificar padrões visuais associados a diferentes tipos de tecidos e condições clínicas.

Nesse contexto, conjuntos de dados padronizados desempenham papel fundamental para o desenvolvimento e comparação de modelos. O PathMNIST, integrante da coleção MedMNIST v2, consiste em um conjunto de imagens histopatológicas coloridas organizadas em nove classes distintas, permitindo a avaliação de diferentes arquiteturas de aprendizado profundo em um ambiente controlado e reproduzível [Yang et al. 2023].

Além da busca por elevados índices de desempenho, cresce também a preocupação com a interpretabilidade dos modelos de Inteligência Artificial. Em aplicações médicas, compreender os fatores que influenciam as decisões do sistema é essencial para aumentar a confiança dos profissionais de saúde e favorecer a adoção dessas tecnologias em cenários reais. Dessa forma, técnicas de Explainable Artificial Intelligence (XAI), como Feature Maps e Grad-CAM, tornam-se ferramentas importantes para a análise do comportamento interno das redes neurais [Selvaraju et al. 2017].

O presente trabalho tem como objetivo implementar, comparar e analisar diferentes arquiteturas de redes neurais para classificação de imagens histopatológicas utilizando o dataset PathMNIST. Inicialmente, foi desenvolvida uma rede Multilayer Perceptron (MLP) em NumPy puro, posteriormente reproduzida em PyTorch para validação da implementação. Em seguida, foram avaliados modelos convolucionais e baseados em Vision Transformers, incluindo CNN própria, ResNet50, EfficientNet-B0, MobileNetV3 Large e ViT-B/16. Por fim, foram aplicadas técnicas de interpretabilidade para compreender as regiões das imagens que mais influenciaram as decisões do modelo final selecionado.

Os resultados obtidos demonstram que modelos pré-treinados submetidos ao processo de *fine-tuning* podem alcançar elevados níveis de desempenho na classificação de tecidos histopatológicos, atingindo acurácia superior a 96% no conjunto de teste oficial e fornecendo evidências visuais que auxiliam a interpretação das predições realizadas.

2. Fundamentação Teórica

2.1. Redes Neurais Artificiais

As Redes Neurais Artificiais (RNAs) constituem uma das principais técnicas de Inteligência Artificial utilizadas para modelagem de problemas complexos de classificação, regressão e reconhecimento de padrões. Inspiradas no funcionamento dos neurônios biológicos, as RNAs são compostas por camadas interconectadas capazes de aprender relações não lineares a partir de exemplos apresentados durante o treinamento. O aprendizado ocorre por meio do ajuste iterativo dos pesos das conexões, normalmente utilizando algoritmos de otimização baseados em gradiente [Goodfellow et al. 2016].

2.2. Multilayer Perceptron

O Multilayer Perceptron (MLP) é uma arquitetura clássica de rede neural composta por uma camada de entrada, uma ou mais camadas ocultas e uma camada de saída. Cada neurônio é totalmente conectado aos neurônios da camada seguinte. O treinamento é realizado por meio do algoritmo de retropropagação do erro (*backpropagation*), que ajusta os pesos da rede visando minimizar uma função de perda. Apesar de sua simplicidade, o MLP é amplamente utilizado para validar conceitos fundamentais relacionados ao aprendizado supervisionado.

2.3. Redes Neurais Convolucionais

As Redes Neurais Convolucionais (CNNs) foram desenvolvidas especificamente para o processamento de imagens. Diferentemente das redes totalmente conectadas, as CNNs utilizam operações de convolução capazes de extrair características espaciais relevantes, como bordas, texturas e padrões complexos. A utilização de filtros convolucionais permite reduzir o número de parâmetros treináveis e aumentar a capacidade de generalização do modelo. Devido a essas características, as CNNs tornaram-se uma das principais abordagens para tarefas de classificação de imagens médicas.

2.4. Transfer Learning e Fine-Tuning

O Transfer Learning consiste na reutilização de modelos previamente treinados em grandes bases de dados para resolver problemas específicos. Essa abordagem reduz significativamente o custo computacional e a quantidade de dados necessários para treinamento. Uma das estratégias mais utilizadas é o *Fine-Tuning*, no qual parte ou todas as camadas do modelo pré-treinado são reajustadas utilizando o conjunto de dados alvo. Arquiteturas como ResNet50 [He et al. 2016], EfficientNet [Tan and Le 2019] e MobileNetV3 [Howard et al. 2019] frequentemente apresentam desempenho superior quando submetidas a esse processo.

2.5. Vision Transformers

Os Vision Transformers (ViTs) representam uma abordagem baseada na arquitetura Transformer originalmente desenvolvida para Processamento de Linguagem Natural. Em vez de utilizar convoluções, os ViTs dividem a imagem em pequenos blocos denominados *patches*, processando-os por meio de mecanismos de atenção. Essa estratégia permite capturar relações globais entre diferentes regiões da imagem, tornando os Vision Transformers uma alternativa relevante às arquiteturas convolucionais tradicionais [Dosovitskiy et al. 2021].

2.6. Explainable Artificial Intelligence

A Explainable Artificial Intelligence (XAI) reúne técnicas voltadas para a interpretação e compreensão das decisões produzidas por modelos de aprendizado de máquina. Em aplicações médicas, a interpretabilidade é especialmente importante, pois permite que especialistas avaliem se as decisões do modelo estão sendo tomadas com base em características relevantes da imagem. Dessa forma, técnicas de XAI contribuem para aumentar a confiança e a transparência dos sistemas inteligentes.

2.7. Grad-CAM e Feature Maps

O Gradient-weighted Class Activation Mapping (Grad-CAM) é uma técnica amplamente utilizada para visualizar as regiões da imagem que mais influenciaram determinada predição realizada por uma rede neural convolucional. O método utiliza os gradientes calculados durante a retropropagação para identificar áreas de maior relevância para a decisão do modelo [Selvaraju et al. 2017]. Complementarmente, os Feature Maps permitem visualizar as ativações produzidas pelos filtros convolucionais em diferentes camadas da rede, fornecendo informações sobre os padrões aprendidos ao longo do processo de treinamento.

3. Metodologia

3.1. Dataset

Os experimentos foram realizados utilizando o dataset PathMNIST, integrante da coleção MedMNIST v2. Foi utilizada a versão oficial PathMNIST+ em resolução 224×224 pixels nas etapas com PyTorch, CNNs, modelos pré-treinados, Vision Transformer e avaliação final. Na Etapa 1, voltada à implementação matemática da MLP em NumPy, foi utilizada a versão reduzida 28×28 , conforme permitido pelo enunciado para essa etapa. Foram utilizados os conjuntos oficiais de treinamento, validação e teste disponibilizados pelos autores da base de dados, preservando a divisão original para garantir a reprodutibilidade dos resultados.

3.2. Ambiente Experimental

O desenvolvimento foi realizado utilizando a linguagem Python e as bibliotecas NumPy, PyTorch, Torchvision, MedMNIST e Matplotlib. Os experimentos foram executados em ambientes Google Colab/Kaggle com aceleração por GPU NVIDIA Tesla T4 com aproximadamente 16GB de VRAM. A utilização de memória de GPU variou conforme a arquitetura avaliada, sendo registrada nos arquivos de resultados da Etapa 3.

As limitações de tempo de GPU influenciaram o número de épocas e a profundidade da busca por hiperparâmetros, especialmente durante a comparação ampla entre arquiteturas. Por esse motivo, a Etapa 3 foi utilizada principalmente para identificar tendências iniciais de desempenho e selecionar a configuração mais promissora, posteriormente reavaliada no treinamento final. Para garantir maior reprodutibilidade, foi utilizada seed global fixa igual a 42 em todas as etapas do projeto.

3.3. Etapa 1: Implementação de uma MLP em NumPy

Na primeira etapa foi desenvolvida uma rede Multilayer Perceptron utilizando exclusivamente NumPy, sem frameworks de diferenciação automática. O foco foi implementar

manualmente os fundamentos do treinamento de redes neurais: propagação direta, cálculo da função de perda, retropropagação e atualização dos pesos.

Por limitação de custo computacional, foi utilizada a versão 28×28 do PathMNIST, conforme permitido pelo enunciado. As imagens foram vetorizadas como entrada da rede totalmente conectada, cuja arquitetura incluiu camadas densas, funções de ativação não lineares e saída compatível com classificação de nove classes.

A função de perda Cross-Entropy, o *forward propagation*, o *backpropagation* e o SGD com Momentum foram todos implementados do zero. Para verificar a corretude dos gradientes analíticos, foi realizado um Gradient Check por aproximação numérica, etapa que aumenta consideravelmente a confiança na implementação manual antes de avançar.

3.4. Etapa 2: Reprodução da MLP em PyTorch

Na segunda etapa a mesma arquitetura foi reimplementada em PyTorch [Paszke et al. 2019], com o objetivo de validar os resultados obtidos em NumPy. Estrutura da rede, função de perda, otimizador e divisão dos dados foram mantidos equivalentes entre as duas versões.

A comparação foi feita pelas curvas de treinamento e pelas métricas de desempenho. O critério de aprovação foi que a diferença de acurácia entre as implementações permanecesse dentro do limite estabelecido pela atividade. A proximidade dos resultados indicou que os componentes críticos da versão manual, como gradientes e atualização de pesos, funcionaram de forma consistente.

3.5. Etapa 3: Comparação entre Arquiteturas Profundas

A terceira etapa avaliou diferentes arquiteturas de redes neurais profundas na tarefa de classificação do PathMNIST. Nesta fase foi utilizada a versão PathMNIST+ com resolução 224×224 pixels, necessária para aproveitar arquiteturas modernas pré-treinadas em ImageNet.

Foram comparadas uma CNN própria e quatro modelos pré-treinados: ResNet50, EfficientNet-B0, MobileNetV3 Large e ViT-B/16. Para os modelos pré-treinados, dois modos foram avaliados. No *feature extraction* as camadas convolucionais ficaram congeladas e só o classificador final foi ajustado. No *fine-tuning* todos os pesos foram liberados para atualização.

A ResNet50 recebeu um grid mais sistemático: dois otimizadores (SGD e AdamW), três taxas de aprendizado (0,01, 0,001 e 0,0001) e os dois modos de treinamento, totalizando 12 combinações. Para os demais modelos foram registradas as melhores configurações viáveis dentro do tempo de GPU disponível nos ambientes Google Colab/Kaggle.

As execuções desta etapa foram curtas por necessidade, servindo para identificar tendências de desempenho, tempo de treinamento e uso de memória. A configuração vencedora, ResNet50 em *fine-tuning* com SGD e taxa de aprendizado 0,01, foi reavaliada em detalhe na etapa final.

3.6. Etapa 4: Explainable Artificial Intelligence

Na quarta etapa foram aplicadas técnicas de XAI ao modelo selecionado. Em problemas de imagem médica, métricas de desempenho isoladas não bastam para avaliar um sistema

de apoio ao diagnóstico; é preciso entender o que a rede está de fato usando para decidir.

Primeiro foram gerados Feature Maps das primeiras camadas convolucionais da ResNet50, revelando quais padrões de baixo nível, como bordas, texturas e estruturas celulares, os filtros aprenderam a detectar. Depois foi aplicado Grad-CAM a três grupos de exemplos: cinco predições corretas com alta confiança, cinco predições incorretas e um caso adicional escolhido para discutir atenção visual potencialmente inadequada.

Nos acertos, os mapas mostraram se a rede focou em regiões histologicamente relevantes. Nos erros, a análise buscou padrões de confusão entre tecidos morfológicamente semelhantes. O caso de atenção inadequada serviu para discutir um problema real de modelos profundos: alta acurácia não garante que o modelo baseie suas decisões exclusivamente em regiões clinicamente ou visualmente relevantes.

3.7. Etapa 5: Treinamento Final e Avaliação

Na quinta etapa, o modelo selecionado foi treinado com a configuração definida na etapa anterior: ResNet50 em modo *fine-tuning*, otimizador SGD, taxa de aprendizado 0,01, 5 épocas, *batch size* 16, RandAugment, *label smoothing* 0,1 e seed global 42.

Durante o treinamento, foram monitoradas as métricas de perda e acurácia nos conjuntos de treinamento e validação. O checkpoint com melhor desempenho de validação foi salvo como `checkpoints/final/best_final_model.pt`. Devido ao tamanho do arquivo, o checkpoint não foi versionado diretamente no repositório, sendo disponibilizado por meio do seguinte link: https://drive.google.com/drive/folders/1hI9ir_JGPJxQYuY1zgNgXdfsCyJyHD8usp=sharing.

Após a seleção do melhor checkpoint, foi realizada uma única avaliação sobre o conjunto oficial de teste, evitando o uso repetido desse conjunto durante a escolha do modelo. As métricas finais calculadas foram acurácia global, F1-Score Macro e matriz de confusão.

4. Resultados e Discussão

4.1. Comparação entre NumPy e PyTorch

As duas primeiras etapas tiveram como objetivo validar a implementação manual dos conceitos fundamentais de aprendizado profundo. A MLP desenvolvida em NumPy alcançou acurácia final de validação de 40,41%, enquanto a implementação equivalente em PyTorch obteve 38,99%. A diferença absoluta observada foi de aproximadamente 1,02 ponto percentual, permanecendo dentro do limite máximo de 2 pontos percentuais estabelecido pela atividade. Além disso, o processo de Gradient Check apresentou erro relativo máximo de $5,84 \times 10^{-9}$, confirmando a consistência da implementação da retropropagação do erro.

4.2. Comparação entre Arquiteturas Profundas

Na terceira etapa foram avaliadas diferentes arquiteturas para classificação das imagens histopatológicas do dataset PathMNIST. Foram comparados modelos convolucionais desenvolvidos especificamente para visão computacional, bem como arquiteturas baseadas em mecanismos de atenção. Deve-se observar que a comparação ampla da Etapa 3 foi

conduzida com execuções curtas, devido às limitações de tempo de GPU. Assim, os resultados dessa etapa foram utilizados principalmente para seleção inicial da configuração mais promissora, posteriormente reavaliada no treinamento final.

Tabela 1. Comparação entre arquiteturas avaliadas na etapa de validação.

Modelo	Estratégia	Otimizador/LR	Acurácia Val.
CNN própria	Treino supervisionado	AdamW / 0,001	85,46%
ResNet50	<i>Feature extraction</i>	AdamW / 0,001	96,79%
ResNet50	<i>Fine-tuning</i>	SGD / 0,01	99,29%
EfficientNet-B0	<i>Fine-tuning</i>	AdamW / 0,0001	99,15%
MobileNetV3 Large	<i>Fine-tuning</i>	AdamW / 0,0001	99,12%
ViT-B/16	<i>Fine-tuning</i>	AdamW / 0,0001	98,91%

O melhor resultado foi obtido pelo modelo ResNet50 operando em modo *fine-tuning* com otimizador SGD e taxa de aprendizado inicial igual a 0,01. Essa configuração alcançou acurácia de validação de 99,29%, superando as demais arquiteturas avaliadas. A validação do checkpoint final selecionado durante o treinamento posterior registrou acurácia de 99,26% na terceira época.

4.3. Curvas de Treinamento e Validação

A Figura 1 apresenta a comparação das curvas de validação obtidas pelos diferentes modelos avaliados durante a etapa de seleção da arquitetura. Observa-se que os modelos pré-treinados apresentaram desempenho superior à CNN desenvolvida do zero, evidenciando os benefícios proporcionados pelo Transfer Learning.




Figura 1. Curvas de validação dos modelos avaliados na Etapa 3.

A Figura 2 apresenta as curvas de treinamento do modelo final selecionado. Observa-se redução consistente da função de perda ao longo das épocas, acompanhada de elevados valores de acurácia tanto no treinamento quanto na validação, indicando adequada capacidade de generalização.

4.4. Avaliação Final

Após a seleção do melhor modelo, foi realizada uma única avaliação sobre o conjunto oficial de teste. Os resultados obtidos demonstram elevado desempenho do sistema de classificação.




Figura 2. Curvas de perda e acurácia do modelo final durante o treinamento.

Tabela 2. Desempenho do modelo final no conjunto de teste.

Métrica	Valor
Acurácia	96,71%
F1-Score Macro	95,41%

4.5. Matriz de Confusão

A Figura 3 apresenta a matriz de confusão obtida no conjunto de teste. Observa-se predominância de valores concentrados na diagonal principal, indicando elevado número de classificações corretas. Os erros observados ocorreram principalmente entre classes que apresentam características histológicas visualmente semelhantes, comportamento esperado em tarefas de classificação de tecidos biológicos.

4.6. Interpretabilidade dos Modelos

Os Feature Maps da primeira camada convolucional mostraram ativações associadas a bordas, variações de textura e contrastes locais, padrões de baixo nível esperados nas camadas iniciais de uma rede convolucional. Esse comportamento indica que o modelo passou a extrair características visuais elementares das imagens histopatológicas antes de combiná-las em representações mais complexas nas camadas posteriores.

O Grad-CAM revelou comportamentos distintos entre acertos e erros. Nas predições corretas com alta confiança, a atenção concentrou-se em regiões com maior densidade celular e contraste de textura, áreas visualmente compatíveis com padrões histológicos relevantes para a classificação.

Nas predições incorretas, os mapas indicaram maior dispersão da atenção ou foco em regiões visualmente menos informativas, sugerindo que parte das confusões ocorreu em amostras com diferenças sutis entre classes e dependentes de contexto morfológico mais amplo.

Um caso adicional foi selecionado para ilustrar uma limitação concreta do modelo: a predição apresentou alta confiança mesmo com atenção concentrada em uma região periférica da lâmina, sem relação visual evidente com as principais estruturas histológicas da amostra. Esse tipo de comportamento não é capturado diretamente pelas métricas agre-




Figura 3. Matriz de confusão 9×9 obtida pelo modelo final no conjunto de teste.

gadas, como acurácia e F1-Score, reforçando que a análise visual por XAI é necessária para complementar a avaliação quantitativa do modelo.

Os resultados reforçam não apenas a capacidade preditiva do modelo selecionado, mas também sua interpretabilidade, característica especialmente relevante em aplicações de apoio ao diagnóstico médico.




Figura 4. Feature Maps extraídos da primeira camada convolucional do modelo ResNet50 final.




Figura 5. Grad-CAM em cinco predições corretas de alta confiança.




Figura 6. Grad-CAM em cinco predições incorretas selecionadas por confiança.




Figura 7. Exemplo de atenção visual potencialmente inadequada para discussão interpretativa.

5. Conclusão

Este trabalho apresentou uma abordagem progressiva para a classificação de tecidos histopatológicos utilizando o dataset PathMNIST, partindo da implementação manual de uma rede neural em NumPy até a avaliação de arquiteturas profundas modernas com PyTorch. A implementação inicial permitiu compreender os fundamentos de *forward propagation*, *backpropagation*, função de perda e otimização com SGD Momentum, enquanto a versão em PyTorch confirmou comportamento compatível com a implementação manual.

Nos experimentos com arquiteturas profundas, os modelos pré-treinados apresentaram desempenho superior à CNN desenvolvida do zero, evidenciando a importância do Transfer Learning em tarefas de visão computacional médica. O melhor resultado foi obtido com a arquitetura ResNet50 em modo *fine-tuning*, utilizando otimizador SGD e taxa de aprendizado inicial igual a 0,01. O modelo final alcançou acurácia de 96,71% e F1-Score Macro de 95,41% no conjunto oficial de teste, demonstrando boa capacidade de generalização.

A aplicação de técnicas de Explainable Artificial Intelligence, especialmente Feature Maps e Grad-CAM, contribuiu para interpretar as regiões das imagens que mais influenciaram as decisões do modelo. Essa etapa é particularmente relevante em aplicações médicas, nas quais não basta apenas obter alta acurácia, sendo necessário também compreender os critérios utilizados pelo sistema para apoiar suas predições.

Como limitações, destaca-se que os experimentos foram conduzidos em um dataset padronizado e controlado, não substituindo validações clínicas com especialistas ou testes em ambientes reais. Além disso, restrições computacionais limitaram o número de épocas e a profundidade da busca por hiperparâmetros. Como trabalhos futuros, recomenda-se ampliar a validação com bases externas, explorar técnicas adicionais de interpretabilidade e aprofundar a análise dos erros entre classes histologicamente semelhantes.

Referências

- Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., et al. (2021). An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations*.
- Goodfellow, I., Bengio, Y., and Courville, A. (2016). *Deep Learning*. MIT Press.
- He, K., Zhang, X., Ren, S., and Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 770–778.
- Howard, A., Sandler, M., Chu, G., Chen, L.-C., Chen, B., Tan, M., Wang, W., Zhu, Y., Pang, R., Vasudevan, V., et al. (2019). Searching for mobilenetv3. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 1314–1324.
- Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., Killeen, T., Lin, Z., Gimelshein, N., Antiga, L., et al. (2019). Pytorch: An imperative style, high-performance deep learning library. In *Advances in Neural Information Processing Systems*, volume 32.

- Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., and Batra, D. (2017). Grad-cam: Visual explanations from deep networks via gradient-based localization. In *Proceedings of the IEEE International Conference on Computer Vision*, pages 618–626.
- Tan, M. and Le, Q. V. (2019). Efficientnet: Rethinking model scaling for convolutional neural networks. In *International Conference on Machine Learning*, pages 6105–6114.
- Yang, J., Shi, R., Wei, D., Liu, Z., Zhao, L., Ke, B., Pfister, H., and Ni, B. (2023). Medmnist v2: A large-scale lightweight benchmark for 2d and 3d biomedical image classification. *Scientific Data*, 10(1):41.